

Vom Datensatz zur Simulation: Wie synthetische Daten entstehen

Markus Steffen

30.06.2026

Agenda

- 1 Einführung
- 2 GAN/CTGAN
- 3 Table Diffusion
- 4 Ausblick und Diskussion
- 5 Quellen

Was sind synthetische Daten

Ein synthetischer Datensatz besitzt die gleichen mathematischen Eigenschaften wie die realen Daten, die er ersetzt, enthält jedoch keine der ursprünglichen Informationen. Er wird erzeugt, indem man echte Daten nimmt, ein generatives Machine-Learning-Modell darauf trainiert und daraus einen neuen Datensatz generiert. Das Ergebnis spiegelt die allgemeinen Muster des Originals wider, liefert aber genug ‚Rauschen‘, um die echten Daten genügend zu maskieren. [MIT-Sloan23]

- 4 Grundpfeiler
 - Fidelity
 - Utility
 - Privacy
 - Reproducibility

Einsatzzwecke für synthetische Daten, oder : wozu braucht man das?

- Datenschutz und Anonymisierung
- Datenverfügbarkeit
- Rapid Prototyping
- Kostenreduktion
- Data Augmentation

Herausforderungen

- Datenqualität
- Trade-Off Qualität vs Privacy
- Bewertung
 - Wie Ergebnisse bewerten ? - keine einheitlicher Standard für Metrik (Vergleichbarkeit)
 - Wie verschiedene Daten vergleichen
 - Wie verschiedene Methodiken vergleichen ?
 - Wie Anonymität einschätzen ?
- sauberes Anforderungsmanagement
- Technische Umsetzung

Was meint ihr?



Abb. 2 ist diese Person real?



Abb. 2

<https://thispersondoesnotexist.com>

GAN - generative adversarial network

Wie funktioniert ein CTGAN

Wie funktioniert ein CTGAN

Wie funktioniert ein CTGAN

Wie funktioniert ein CTGAN

Come with me if you want to live

Veranschaulichung der Herausforderungen

Tabelle: Messwerte unterschiedlicher Quellen**FHIR als Netzwerk**

Quelle	M1	M2	M3	M4	Target
Krankenhaus A	120	7.5	80	1.2	100
Krankenhaus B	12	7500	0.08	1200	100
Labor C	119	7.4	78	1.1	100

HL7v2 vs FHIR

Wie funktioniert ein CTGAN

Wie funktioniert ein CTGAN

Andere Möglichkeiten zur synth. Datenerzeugung

- SimbaML - simulation based machine Learning
- TVAE
- LLM
- Ohne Standards bleiben Daten Inseln – mit Standards werden sie ein Netzwerk.

Fazit

- Standards = Grundlage für Vergleichbarkeit, Integrierbarkeit, Qualität und schnelle Entscheidungen
- Komplexität der Anonymisierung sinkt erheblich bei einheitlichen Datenstandards
- Umsetzung braucht Zeit, Koordination und Ressourcen
- Ohne Standards bleiben Daten Inseln – mit Standards werden sie ein Netzwerk.

Quellen

- HL7 International (o.D.). *Patient – FHIR v6.0.0-ballot3*. Verfügbar unter: [⟨https://build.fhir.org/patient.html⟩](https://build.fhir.org/patient.html) (Zugegriffen: 8. September 2025).
- HL7 Deutschland (o.D.). *HL7 v2.x Nachrichten*. Verfügbar unter: [⟨https://hl7.de/themen/hl7-v2-x-nachrichten/⟩](https://hl7.de/themen/hl7-v2-x-nachrichten/) (Zugegriffen: 8. September 2025).
- ResearchGate (o.D.). *FHIR Resources Schema: It represents the FHIR resources and corresponding properties*. Verfügbar unter: [⟨https://www.researchgate.net/figure/FHIR-Resources-Schema-It-represents-the-FHIR-resources-and-corresponding-properties-to_fig2_372962413⟩](https://www.researchgate.net/figure/FHIR-Resources-Schema-It-represents-the-FHIR-resources-and-corresponding-properties-to_fig2_372962413) (Zugegriffen: 9. September 2025).
- Hufstедler, H. u.a. (2024). „Navigating data standards in public health: A brief report from a data-standards meeting“. *Journal of Global Health*, 14, S. 03024. Verfügbar unter: [⟨https://doi.org/10.7189/jogh.14.03024⟩](https://doi.org/10.7189/jogh.14.03024).
- Robert Koch-Institut [RKI] (2025). *Public Health – mehr Gesundheit für alle*. Verfügbar unter: [⟨https://www.rki.de/DE/Themen/Gesundheit-und-Gesellschaft/Public-Health/public-health.html⟩](https://www.rki.de/DE/Themen/Gesundheit-und-Gesellschaft/Public-Health/public-health.html) (Zugegriffen: 8. September 2025).
- Wikipedia (2025). *Public Health*. Verfügbar unter: [⟨https://de.wikipedia.org/w/index.php?title=Public_Health&oldid=258201254⟩](https://de.wikipedia.org/w/index.php?title=Public_Health&oldid=258201254) (Zugegriffen: 8. September 2025).

Vielen Dank für Eure
Aufmerksamkeit!